

Deserción escolar en Bolivia

Análisis aplicado a microdatos EH2025 para identificar perfiles de riesgo educativo y orientar decisiones públicas.

DAYSÍ MARIBEL QUISPE GUARACHI

Caso 1 · EH2025 · Python/Colab · UPEA


Del dato crudo a una lectura social



El enfoque se mantuvo a nivel de persona, porque la pregunta central es quién asiste y quién queda fuera del sistema educativo.

La variable objetivo: una minoría pequeña, pero crítica

Distribución de la asistencia escolar



5,21%

no asiste o no está matriculado

544


casos de no asistencia en la muestra analítica

9.904

casos de asistencia escolar

La clase está desbalanceada: si solo miramos accuracy, un modelo puede parecer bueno aunque no detecte bien a quienes están en riesgo.

La no asistencia no se distribuye igual en el territorio



LECTURA HUMANA

Pando aparece con la tasa más alta;
Cochabamba con la más baja.

La lectura departamental ayuda a ubicar
dónde priorizar observación y seguimiento,
pero no explica por sí sola las causas.

Mayor tasa observada


Pando
8,01%

Menor tasa observada


Cochabamba
3,63%

El territorio pesa más que el sexo en esta primera lectura

Ruralidad: diferencia clara




Sexo: diferencia menor



La brecha rural-urbana es más marcada que la diferencia entre hombres y mujeres: 8,93% frente a 4,00%.

La edad marca el punto de quiebre

No asistencia escolar según edad (%)



HALLAZGO CLAVE

A partir de los 17 años la curva cambia de escala.

A los 18 años llega a 18,73% y a los 19 años sube a 37,18%.

37,18%

no asistencia a los 19 años

La permanencia educativa debe leerse como un problema de transición adolescente: el riesgo se concentra cerca del cierre de la etapa escolar.


Tres perfiles educativos aparecen en los datos



El clustering no etiqueta “culpables”; ayuda a reconocer perfiles de atención diferenciada.

El mejor modelo depende del objetivo de política pública

Comparación de métricas de clasificación (%)



DECISIÓN TÉCNICA

Para encontrar casos de riesgo, priorizamos el recall.

La Regresión Logística detecta 86,24% de los casos de no asistencia, aunque genera más alertas falsas.


92,18%

AUC-ROC Regresión Logística

Random Forest tiene mayor accuracy, pero menor recall para la clase que nos preocupa.

Qué variables ayudan más a predecir el riesgo

Top 10 variables de importancia en Random Forest



Lectura simple

La edad concentra la mayor señal predictiva. El ingreso del hogar aparece en segundo lugar. Luego se combinan nivel educativo, idioma, vivienda y territorio.

Cuidado interpretativo


Importancia predictiva no equivale a causalidad.

De los hallazgos a decisiones más focalizadas

1

Hallazgo


La no asistencia sube con fuerza entre 17 y 19 años.



2

Perfil

Cluster rural vulnerable y adolescentes urbanos concentran mayor riesgo.



3

Acción

Seguimiento preventivo antes del abandono: becas, tutorías, alertas y apoyo familiar.

La utilidad del análisis no está en “predecir por predecir”, sino en anticipar dónde mirar primero y cómo distribuir mejor el esfuerzo institucional.

Tres recomendaciones concretas

01

Focalizar permanencia en 17–19 años

Activar seguimiento preventivo en los últimos años de secundaria: alertas tempranas, tutorías, orientación vocacional y apoyo económico condicionado a permanencia.

02

Intervención diferenciada rural

Cruzar riesgo educativo con acceso a servicios, transporte, conectividad y distancia a unidades educativas para priorizar comunidades de mayor vulnerabilidad.

03

Tablero territorial de monitoreo

Usar mapas, clusters y métricas para que municipios y departamentos observen cambios y evalúen políticas con evidencia actualizada.

Estas recomendaciones son orientativas: los modelos muestran asociaciones estadísticas y perfiles de riesgo, no efectos causa les.

Cierre: evidencia lista para entregar

La historia que cuentan los datos

La no asistencia escolar observada es baja en promedio, pero se concentra con claridad en edades mayores, área rural y determinados perfiles territoriales. El análisis permite pasar de un promedio nacional a decisiones más focalizadas.

12

diapositivas
(máx. 15)

2

modelos
comparados

5+

visualizaciones
interactivas

Archivos de entrega

- notebook .ipynb con análisis completo
- dataset_procesado.csv
- predicciones.csv
- visualizaciones e imágenes de salida
- storytelling.pdf / PowerPoint
- README.md + requirements.txt